HW1：基于 NumPy 从零构建三层神经网络分类器实现地表覆盖图像分类

姓名：_____ 学号：_____

2026 年 4 月 29 日

摘要

本次实验围绕 EuroSAT_RGB 遥感图像分类任务展开，目标是在不使用 PyTorch、TensorFlow 或 JAX 的前提下，用 NumPy 手动实现一个三层 MLP 分类器。代码中前向传播、反向传播、Softmax 交叉熵、L2 正则化、SGD/momentum 更新和学习率衰减都由矩阵运算直接完成。实验过程中，我将数据划分为训练集、验证集和测试集，并用验证集准确率选择最终模型。经过几轮超参数调整后，最佳模型在测试集上达到 68.27% 的准确率。报告中还整理了训练曲线、混淆矩阵、第一层权重可视化以及部分错误样例，用来分析 MLP 在这个遥感任务上的表现和局限。

1 任务描述

本次作业要求从零搭建一个三层神经网络分类器，并在 EuroSAT_RGB 数据集上完成地表覆盖图像分类。这个数据集一共有 10 个类别，分别为 AnnualCrop、Forest、HerbaceousVegetation、Highway、Industrial、Pasture、PermanentCrop、Residential、River 和 SeaLake。每张样本都是 64×64 的 RGB 遥感图像，类别之间既有比较容易区分的水体、森林和居民区，也有外观比较接近的农田、牧场和草地。

实验中没有使用现成的自动微分框架，而是只用 NumPy 完成矩阵运算和梯度计算。主要训练代码位于 `src/train_numpy_mlp.py`，报告中使用的图像和结果文件都保存在 `outputs/` 目录下。

2 数据处理

由于 MLP 需要把图像直接展平成向量，如果保留 64×64 的原始分辨率，第一层参数量会明显增大，训练也更容易过拟合。因此实验中先把图像缩放到 32×32，再展平成长度为 $32 \times 32 \times 3 = 3072$ 的向量。像素值先归一化到 $[0, 1]$，随后用训练集的均值和标准差做标准化。数据划分时使用固定随机种子并按类别分层抽样，这样训练集、验证集和测试集中的类别比例基本一致，后续比较不同超参数时也更公平。

表 1: 数据集划分

数据子集	样本数量
训练集	18900
验证集	4050
测试集	4050

3 模型结构与训练方法

模型采用作业要求的三层全连接结构，可以理解为两个隐藏层加一个 Softmax 输出层。设输入样本为 x，网络前向传播形式为：

$$h_1 = f(xW_1 + b_1), \tag{1}$$

$$h_2 = f(h_1W_2 + b_2), \tag{2}$$

$$o = h_2W_3 + b_3, \tag{3}$$

$$p_i = \frac{\exp(o_i)}{\sum_j \exp(o_j)}. \tag{4}$$

其中 $f(\cdot)$ 为隐藏层激活函数，实验中比较了 ReLU 和 Tanh。分类损失使用 Softmax 交叉熵，同时加入 L2 正则化来限制权重过大：

$$\mathcal{L} = -\frac{1}{N}\sum_{n=1}^{N}\log p_{n,y_n} + \frac{\lambda}{2}\sum_l \|W_l\|_2^2. \tag{5}$$

训练过程使用小批量随机梯度下降。在调参过程中我发现，单纯 SGD 后期会比较容易震荡，所以又加入了 momentum 动量项作为一个可选超参数。每轮训练后都会在验证集上评估一次，并保存验证集准确率最高的参数。学习率采用指数衰减策略：

$$\eta_t = \eta_0\gamma^t, \tag{6}$$

其中 η_0 为初始学习率，γ 为衰减系数。

4 超参数搜索

实验主要比较了隐藏层规模、激活函数、初始学习率、学习率衰减、L2 正则化强度和 momentum。考虑到每次训练都在 CPU 上完成，而且本次作业重点不是堆很大的搜索规模，所以我只保留了几组比较有代表性的配置：一组较宽的 ReLU 模型、几组较小的 ReLU 模型、一个不加 momentum 的对照，以及一个 Tanh 对照。

表 2: 超参数搜索结果

实验编号	隐藏层维度	激活函数	初始学习率	学习率衰减	L2 正则化	动量	最优验证准确率
1	[384, 96]	ReLU	0.010	0.97	1×10^{-3}	0.9	67.68%
2	[256, 64]	ReLU	0.012	0.97	1×10^{-3}	0.9	67.33%
3	[256, 64]	ReLU	0.012	0.97	7×10^{-4}	0.9	67.01%
4	[256, 64]	ReLU	0.035	0.95	7×10^{-4}	0.0	66.91%
5	[256, 128]	Tanh	0.015	0.95	1×10^{-4}	0.0	58.59%

从表中可以看到，最终效果最好的是实验 1：隐藏层维度为 $[384, 96]$，激活函数为 ReLU，初始学习率为 0.010，学习率衰减系数为 0.97，L2 正则化强度为 1×10^{-3}，momentum 为 0.9。这个结果也比较符合实际训练过程中的观察：加入 momentum 后，模型在较小学习率下依然能比较快地下降；同时隐藏层稍微加宽以后，模型表达能力比 $[256, 64]$ 更强。为了避免训练准确率过高后明显过拟合，我把 L2 正则化也相应调大了一些。Tanh 对照组的结果明显偏低，说明在这个输入标准化后的 MLP 任务中，ReLU 更容易优化。

5 训练曲线与测试结果

图 1 展示了最佳模型训练过程中的损失和准确率变化。整体来看，训练损失下降比较明显，训练准确率后期已经接近饱和；验证准确率在第 73 轮附近达到最高。训练集和验证集之间存在一定差距，说明模型已经学到了不少训练集特征，但泛化能力仍然受限。这一点也符合 MLP 的特点：图像被展平以后，空间邻接关系没有被显式利用，模型需要自己从一长串像素中学习空间模式。

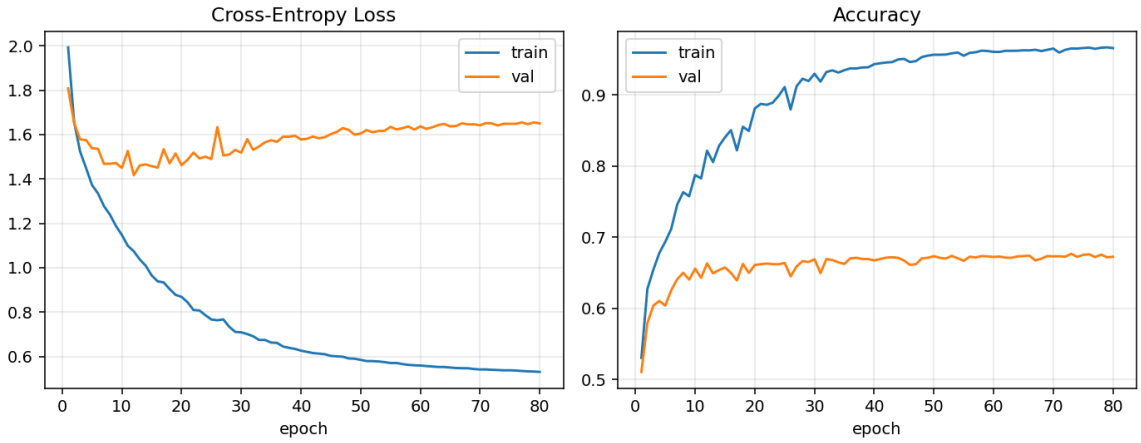

图 1: 训练集与验证集上的损失曲线和准确率曲线

使用验证集上保存的最佳权重，在测试集上得到的准确率为 68.27%。图 2 给出了测试集混淆矩阵。从结果看，Forest、Industrial 和 SeaLake 的识别相对稳定，因为这些类别在颜色分布和整体纹理上比较有辨识度。相比之下，AnnualCrop、PermanentCrop、Pasture 和 HerbaceousVegetation 更容易互相混淆，这几个类别本身都和植被或农田有关，在低分辨率图像中边界和纹理差异并不总是明显。

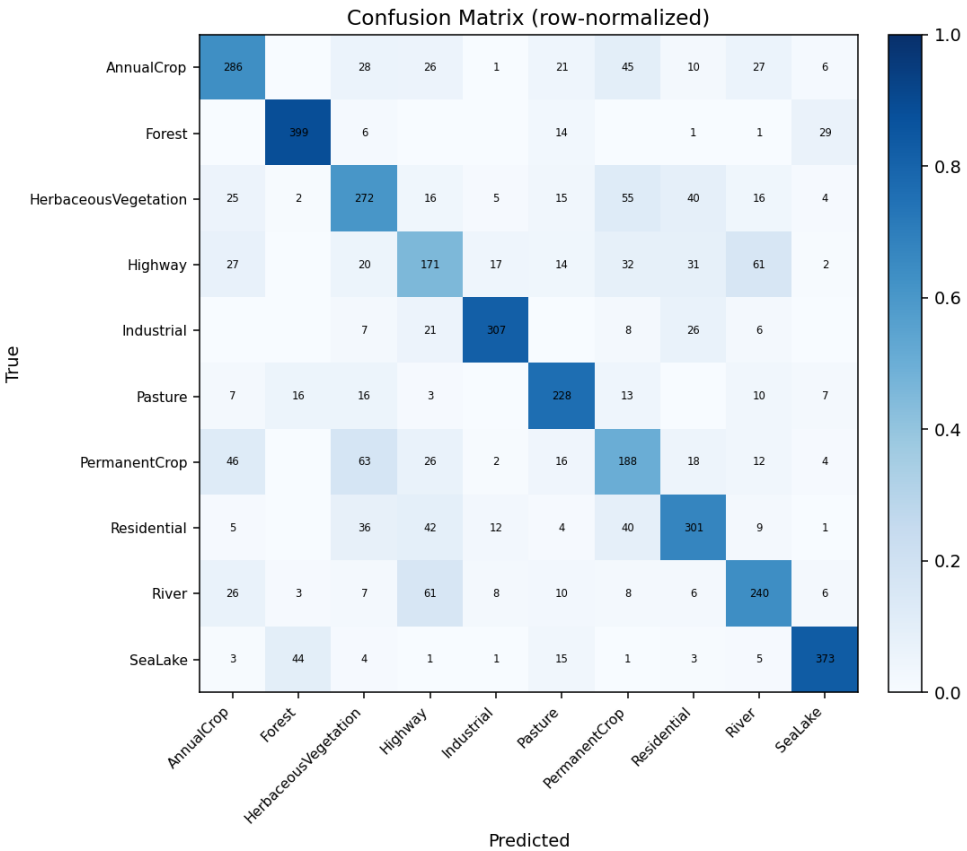

图 2: 测试集混淆矩阵

6 第一层权重可视化

为了更直观地看模型到底学到了什么，我把第一层隐藏层权重重新恢复成 $32 \times 32 \times 3$ 的图像形式，并选取范数较大的若干隐藏单元进行可视化，如图 3 所示。这些权重图不像卷积网络中的滤波器那样呈现清晰的局部边缘，而更多表现为大块颜色和低频空间响应。我的理解是，MLP 在这里主要依赖全局颜色倾向和粗粒度纹理来判断类别，例如水体偏蓝、植被偏绿、城市区域亮度和纹理更复杂；但它对道路形状、河流弯曲等局部结构的建模能力比较弱。

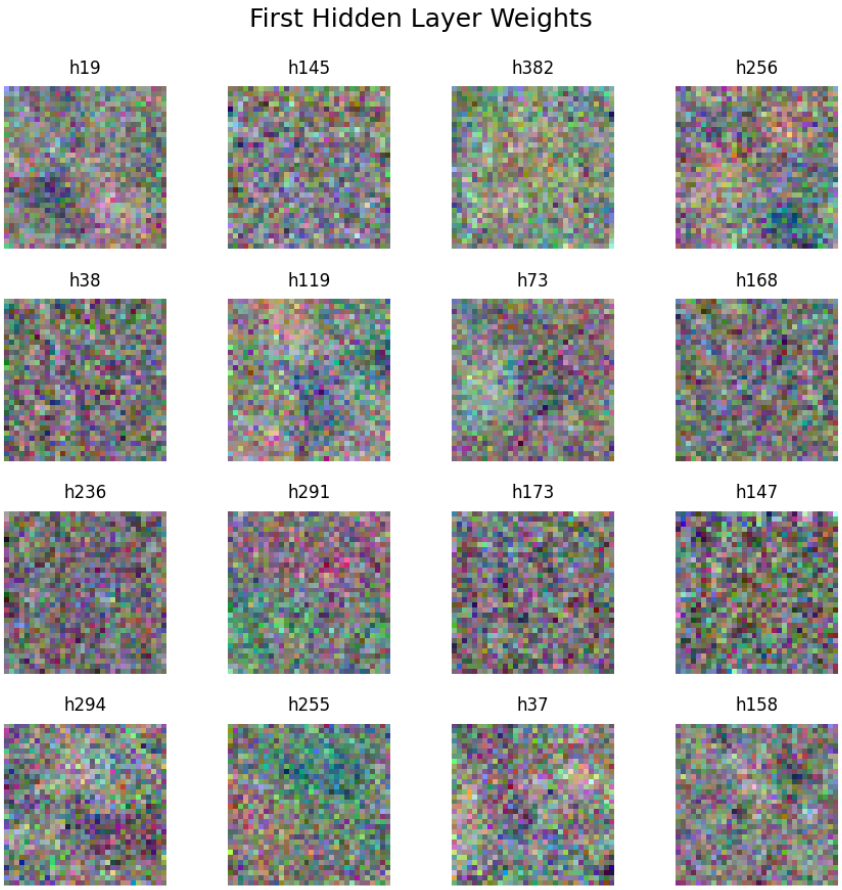

图 **3:** 第一层隐藏层权重可视化

7 错误分析

图 4 展示了测试集中若干分类错误样例。比较典型的错误是 Highway 和 River 的混淆，因为二者在遥感图像中都可能呈现细长、连续的线状结构；如果周围背景比较相似，MLP 很难只靠展平后的像素判断它到底是道路还是河流。另一类错误集中在 AnnualCrop、PermanentCrop、Pasture 和 HerbaceousVegetation 之间，这些图像通常都有大面积绿色或棕色区域，低分辨率下纹理差别不够明显。

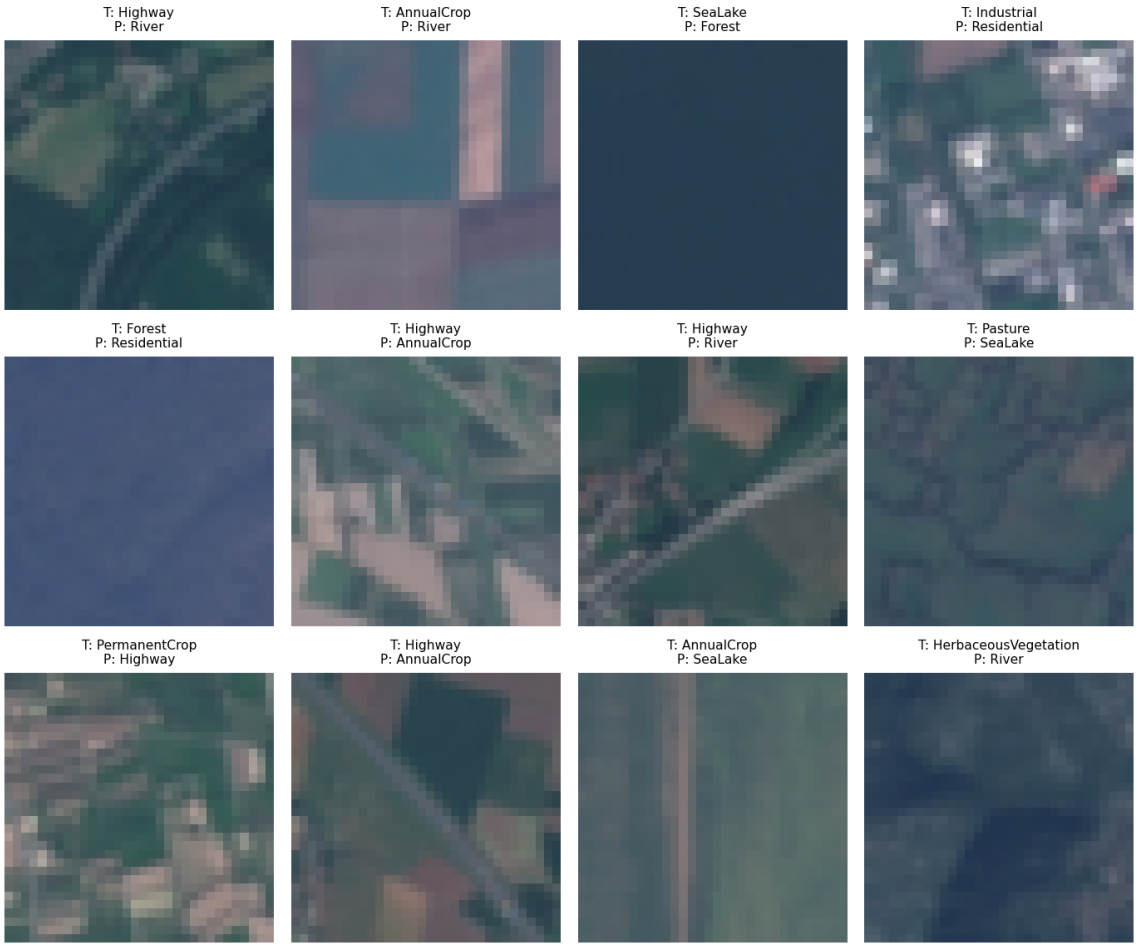

图 4: 测试集分类错误样例

总体来看，错误主要来自两方面。第一，遥感图像类别本身就存在视觉相似性，例如农田、牧场和草地的颜色与纹理非常接近；第二，MLP 没有卷积网络那种局部感受野和平移不变性，图像展平后相邻像素之间的空间关系没有被很好地保留下来。因此，如果允许使用 CNN，准确率应该还有较大提升空间。不过本次作业的重点是手工实现神经网络训练流程，从这个角度看，当前结果已经能够说明 MLP 在该任务上的基本能力和局限。

8 复现说明与提交链接

在作业目录下运行以下命令可以复现实验：

```
python3 src/train_numpy_mlp.py --data-dir EuroSAT_RGB --out-dir outputs --search
```

运行以下命令可以编译本文的 LaTeX 报告：

```
xelatex report_hw1.tex
```

模型权重已保存为：

```
outputs/best_model.npz
```

作业要求的公开仓库和模型下载链接如下。

表 3: 提交链接

项目	链接
Public GitHub Repo	https://github.com/huang200309/eurosat-numpy-mlp-hw1
模型权重下载地址	https://github.com/huang200309/eurosat-numpy-mlp-hw1/raw/main/outputs/be