HW1：基于 NumPy 从零构建三层神经网络分类器 实现地表覆盖图像分类

姓名：_____ 学号：_____

2026 年 4 月 29 日

摘要

本文基于 EuroSAT_RGB 遥感图像数据集，实现了一个不依赖 PyTorch、TensorFlow 或 JAX 的多层感知机分类器。模型的前向传播、反向传播、Softmax 交叉熵损失、L2 正则化、随机梯度下降、动量项以及学习率衰减均使用 NumPy 手动实现。实验采用分层划分方式构造训练集、验证集和测试集，并通过验证集准确率保存最优模型权重。最终最佳模型在测试集上取得了 68.27% 的分类准确率。本文同时给出了训练曲线、混淆矩阵、第一层权重可视化和错误样例分析。

1 任务描述

本次作业要求手工搭建一个三层神经网络分类器，在 EuroSAT_RGB 数据集上完成地表覆盖图像分类任务。EuroSAT_RGB 包含 10 个类别，分别为 AnnualCrop、Forest、HerbaceousVegetation、Highway、Industrial、Pasture、PermanentCrop、Residential、River 和 SeaLake。每张图像为 RGB 遥感图像，原始大小为 64×64。

本实验严格遵守作业要求：不使用 PyTorch、TensorFlow、JAX 等自动微分深度学习框架，仅使用 NumPy 完成矩阵运算和梯度计算。代码文件为 `src/train_numpy_mlp.py`，生成报告所用的图像位于 `outputs/` 目录下。

2 数据处理

为了降低全连接网络的输入维度和训练开销，实验将所有图像缩放为 32×32 的 RGB 图像，然后展平成长度为 $32 \times 32 \times 3 = 3072$ 的向量。像素值先归一化到 $[0, 1]$，再使用训练集均值和标准差进行标准化。数据集采用固定随机种子进行分层划分，保证每个类别在训练集、验证集和测试集中的比例一致。

表 1: 数据集划分

数据子集	样本数量
训练集	18900
验证集	4050
测试集	4050

3 模型结构与训练方法

模型采用三层全连接神经网络结构，即输入层、两个隐藏层和一个 Softmax 输出层。设输入样本为 x，网络前向传播形式为：

$$h_1 = f(xW_1 + b_1), \tag{1}$$

$$h_2 = f(h_1W_2 + b_2), \tag{2}$$

$$o = h_2W_3 + b_3, \tag{3}$$

$$p_i = \frac{\exp(o_i)}{\sum_j \exp(o_j)}. \tag{4}$$

其中 $f(\cdot)$ 为隐藏层激活函数，本实验对 ReLU 和 Tanh 进行了比较。损失函数采用 Softmax 交叉熵，并加入 L2 正则化：

$$\mathcal{L} = -\frac{1}{N}\sum_{n=1}^{N}\log p_{n,y_n} + \frac{\lambda}{2}\sum_l \|W_l\|_2^2. \tag{5}$$

训练过程使用小批量随机梯度下降，并在部分配置中加入 momentum 动量项以改善优化稳定性。每轮训练后在验证集上评估准确率，并保存验证集准确率最高的模型参数。学习率采用指数衰减策略：

$$\eta_t = \eta_0\gamma^t, \tag{6}$$

其中 η_0 为初始学习率，γ 为衰减系数。

4 超参数搜索

实验比较了不同隐藏层规模、激活函数、学习率、学习率衰减、L2 正则化强度和 momentum。由于本作业重点是从零实现反向传播和优化过程，超参数搜索规模保持较小，以便在普通 CPU 环境中可复现。

表 2: 超参数搜索结果

实验编号	隐藏层维度	激活函数	初始学习率	学习率衰减	L2 正则化	动量	最优验证准确率
1	[384, 96]	ReLU	0.010	0.97	1×10^{-3}	0.9	67.68%
2	[256, 64]	ReLU	0.012	0.97	1×10^{-3}	0.9	67.33%
3	[256, 64]	ReLU	0.012	0.97	7×10^{-4}	0.9	67.01%
4	[256, 64]	ReLU	0.035	0.95	7×10^{-4}	0.0	66.91%
5	[256, 128]	Tanh	0.015	0.95	1×10^{-4}	0.0	58.59%

最佳配置为实验 1：隐藏层维度为 $[384, 96]$，激活函数为 ReLU，初始学习率为 0.010，学习率衰减系数为 0.97，L2 正则化强度为 1×10^{-3}，momentum 为 0.9。相比不使用动量的配置，momentum 能在较小学习率下更快进入高准确率区域；同时较强的 L2 正则化缓解了动量训练后期训练准确率较高带来的过拟合风险。Tanh 对照组收敛较慢，最终准确率明显低于 ReLU。

5 训练曲线与测试结果

图 1 展示了最佳模型在训练过程中的交叉熵损失和准确率变化。可以看到，训练损失整体随训练轮数下降，训练准确率持续上升；验证准确率在第 73 轮附近达到最高。由于模型为全连接网络，且输入图像被展平，模型缺少卷积网络中的局部平移不变性，因此整体准确率仍然有限。

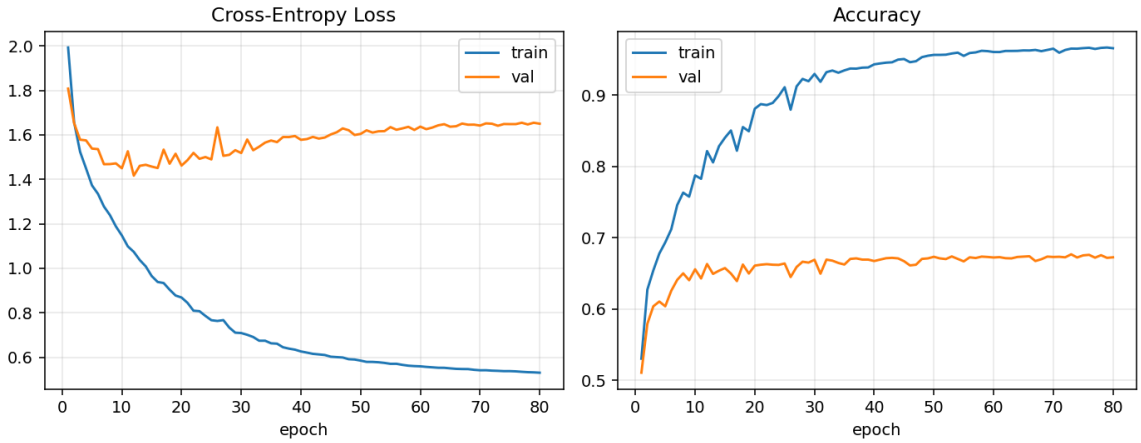

图 1: 训练集与验证集上的损失曲线和准确率曲线

使用验证集上保存的最佳权重，在测试集上得到的准确率为 68.27%。图 2 给出了测试集混淆矩阵。从混淆矩阵可以看出，Forest、Industrial 和 SeaLake 等类别识别相对较好；而 AnnualCrop、PermanentCrop、Pasture、HerbaceousVegetation 之间更容易混淆，这些类别在颜色和纹理上具有较高相似性。

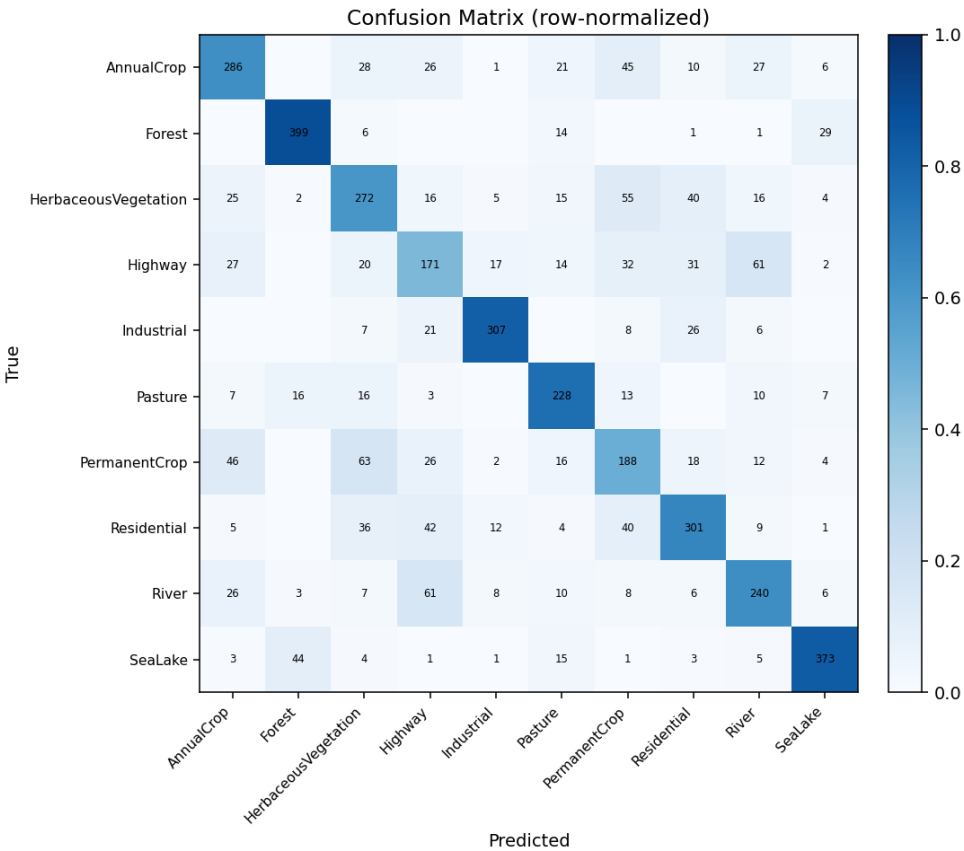

图 2: 测试集混淆矩阵

6 第一层权重可视化

为了观察模型是否学习到空间或颜色模式，将第一层隐藏层权重重新恢复为 $32 \times 32 \times 3$ 的图像形式，并选择范数较大的若干隐藏单元进行可视化，如图 3 所示。由于 MLP 直接处理展平后的像素向量，第一层权重主要表现为较粗粒度的颜色和低频空间响应，而不是卷积网络中常见的局部边缘滤波器。这说明模型能够捕捉一定的植被、水体、土壤和城市区域颜色倾向，但对局部结构的建模能力较弱。

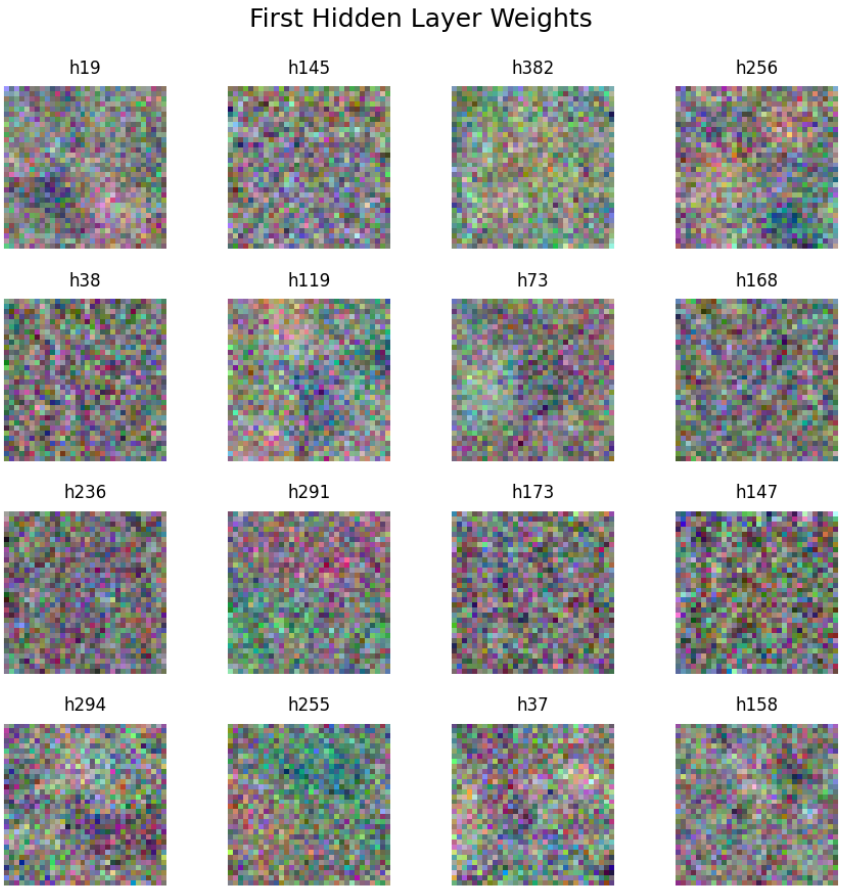

图 **3:** 第一层隐藏层权重可视化

7 错误分析

图 4 展示了测试集中若干分类错误样例。可以观察到，Highway 和 River 常出现混淆，因为二者在遥感图像中都可能呈现细长、连续的线状结构。AnnualCrop、PermanentCrop、Pasture 和 HerbaceousVegetation 之间也较容易混淆，因为这些类别通常具有相近的绿色或棕色纹理，并且在低分辨率图像中边界和几何形状并不总是清晰。

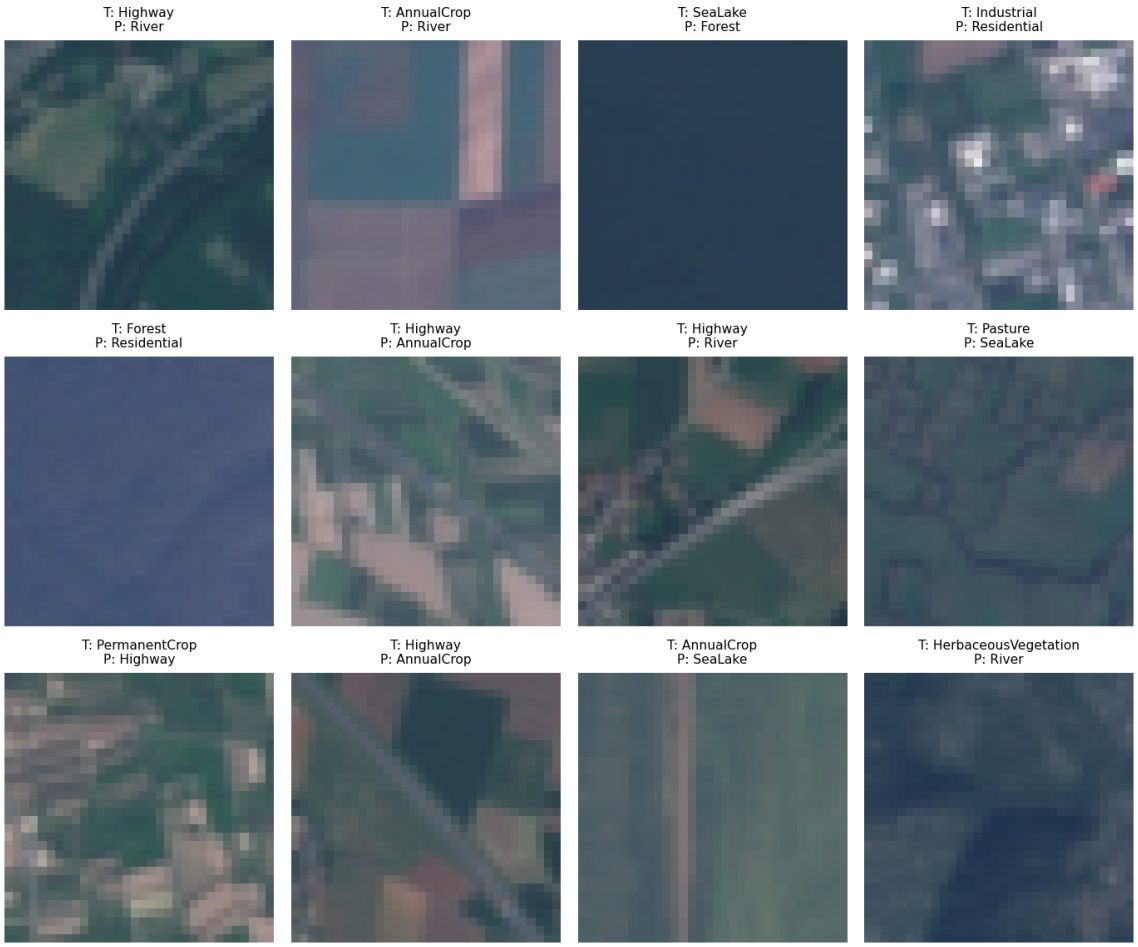

图 4: 测试集分类错误样例

总体来看，错误主要来自两方面。第一，遥感场景类别本身存在视觉相似性，例如农田、牧场和草地的光谱与纹理特征相近；第二，MLP 缺少显式的空间局部建模能力，图像展平后相邻像素关系没有被结构化利用。因此，若允许使用卷积神经网络，预期可以进一步提升分类性能。但本实验的重点在于手工实现自动微分以外的神经网络训练流程，当前结果能够反映 MLP 在该任务上的基本能力和局限。

8 复现说明与提交链接

在作业目录下运行以下命令可以复现实验：

```
python3 src/train_numpy_mlp.py --data-dir EuroSAT_RGB --out-dir outputs --search
```

运行以下命令可以编译本文的 LaTeX 报告：

```
xelatex report_hw1.tex
```

模型权重已保存为：

```
outputs/best_model.npz
```

作业要求的公开仓库和模型下载链接如下。

表 3: 提交链接

项目	链接
Public GitHub Repo	https://github.com/huang200309/eurosat-numpy-mlp-hw1
模型权重下载地址	https://github.com/huang200309/eurosat-numpy-mlp-hw1/raw/main/outputs/be